AURORA SIGER

Análise de Telemetria Operacional de Sistema Aeroespacial

Arthur Apolonio de Oliveira
Matheus Bejarano da Costa Resende
Dayvid Daniel Duarte Ramos
Bryan Lima Garcia
Vinicius Valiati Costa

Link para o Github

Ciência da Computação · FIAP · 2026

Atividade Integradora — Fase 1

1.1 Organização e Descrição da Telemetria

O sistema de telemetria da nave Aurora Siger é composto por **10.000 leituras simuladas**, organizadas em um DataFrame onde cada linha representa um instante de monitoramento e cada coluna um parâmetro crítico do sistema.

Parâmetro	Tipo	Faixa Segura
temp_interna	Contínuo	15 – 30 °C
temp_externa	Contínuo	-20 – 40 °C
energia_pct	Contínuo	≥80%
pressao_bar	Contínuo	3,0 – 5,0 bar
integridade	Binário (0/1)	1
mod_navegacao	Binário (0/1)	1
mod_comunicacao	Binário (0/1)	1
mod_propulsao	Binário (0/1)	1

Para simular condições realistas, cada parâmetro recebeu uma taxa de discrepância entre **10% e 20%**, introduzindo intencionalmente leituras fora dos limites seguros.

1.2 Algoritmo de Verificação

O algoritmo analisa cada leitura e a classifica automaticamente como **"PRONTO PARA DECOLAR"** ou **"DECOLAGEM ABORTADA"**, com base nas faixas seguras predefinidas.

Pseudocódigo

pseudocode.txt

```
PARA CADA leitura no dataset:

SE temp_interna < 15 OU temp_interna > 30 => DECOLAGEM ABORTADA
SE temp_externa < -20 OU temp_externa > 40 => DECOLAGEM ABORTADA
SE integridade != 1 => DECOLAGEM ABORTADA
SE energia_pct < 80 => DECOLAGEM ABORTADA
SE pressao_bar < 3.0 OU pressao_bar > 5.0 => DECOLAGEM ABORTADA
SE mod_navegacao != 1 => DECOLAGEM ABORTADA
SE mod_comunicacao != 1 => DECOLAGEM ABORTADA
SE mod_propulsao != 1 => DECOLAGEM ABORTADA
```

```

SE todas as condicoes satisfeitas => PRONTO PARA DECOLAR
```

Lógica de Implementação

As verificações foram vetorizadas com operações booleanas do Pandas, processando as 10.000 leituras simultaneamente.Cada parâmetro gera uma série booleana que, combinada com o operador &, determina o status final qualquer falha individual é suficiente para classificar como **"DECOLAGEM ABORTADA"**. O dicionário CHECKS registra quais parâmetros falharam em cada leitura, tornando o sistema diagnóstico.

1.3 Script em Python

Imports e Configurações

imports.py

```
import numpy as np
import pandas as pd
import random
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_style("white")
sns.set_context("talk")
```

Etapa 1 — Geração e Leitura dos Dados

Os dados são simulados via NumPy, gerando **10.000 leituras** com taxa de discrepância entre 10% e 20% por parâmetro.

geracao_dados.py

```
N = 10000
discrepancia_range = [0.10, 0.20]

faixas = {
'temp_interna' : (15, 30),
'temp_externa' : (-20, 40),
'energia_pct' : (80, 100),
'pressao_bar' : (3.0, 5.0)
}

modulos = ['integridade', 'mod_navegacao', 'mod_comunicacao', 'mod_propulsao']

def gerar_valores(min_val, max_val, N, discrepancia):
```

```
n_ok = int(N * (1 - discrepancia))
n_bad = N - n_ok
ok = np.random.uniform(min_val, max_val, n_ok)
bad_baixo = np.random.uniform(min_val - (max_val - min_val), min_val - 0.1, n_bad//2)
bad_alto = np.random.uniform(max_val + 0.1, max_val + (max_val - min_val), n_bad -
n_bad//2)
return np.concatenate([ok, bad_baixo, bad_alto])

df = pd.DataFrame({'leitura_id': range(1, N+1)})

for param, (min_val, max_val) in faixas.items():
disc = np.random.uniform(*discrepancia_range)
df[param] = gerar_valores(min_val, max_val, N, disc).round(2)

for param in modulos:
disc = np.random.uniform(*discrepancia_range)
df[param] = np.random.choice([1, 0], size=N, p=[1-disc, disc])

df = df.sample(frac=1).reset_index(drop=True)
df.head(5)
```

Etapa 2 — Execução das Verificações

Cada parâmetro é verificado individualmente. Uma única falha é suficiente para abortar a decolagem.

verificacoes.py

```
temp_interna_ok = (df['temp_interna'] >= 15.0) & (df['temp_interna'] <= 30.0)
temp_externa_ok = (df['temp_externa'] >= -20.0) & (df['temp_externa'] <= 40.0)
integridade_ok = df['integridade'] == 1
energia_ok = df['energia_pct'] >= 80.0
pressao_ok = (df['pressao_bar'] >= 3.0) & (df['pressao_bar'] <= 5.0)
mod_navegacao_ok = df['mod_navegacao'] == 1
mod_comunicacao_ok = df['mod_comunicacao'] == 1
mod_propulsao_ok = df['mod_propulsao'] == 1

sistemas_ok = (
mod_navegacao_ok
& mod_comunicacao_ok
& mod_propulsao_ok
)

condicoes_ok = (
temp_interna_ok
& temp_externa_ok
& integridade_ok
& energia_ok
& pressao_ok
)
```

```

df['status'] = 'DECOLAGEM ABORTADA'
df.loc[sistemas_ok & condicoes_ok, 'status'] = 'PRONTO PARA DECOLAR'
df.head()
```

Etapa 3 — Tipos de Falha

Uma nova coluna é adicionada ao dataset registrando quais parâmetros falharam em cada leitura.

falhas.py

```
CHECKS = {
'temp_interna' : lambda v: 15.0 <= v <= 30.0,
'temp_externa' : lambda v: -20.0 <= v <= 40.0,
'integridade' : lambda v: v == 1,
'energia_pct' : lambda v: v >= 80.0,
'pressao_bar' : lambda v: 3.0 <= v <= 5.0,
'mod_navegacao' : lambda v: v == 1,
'mod_comunicacao' : lambda v: v == 1,
'mod_propulsao' : lambda v: v == 1,
}

df['falhas'] = df.apply(
lambda row: [p for p, fn in CHECKS.items() if not fn(row[p])],
axis=1
)

df.loc[df['status'] == 'DECOLAGEM ABORTADA',
['leitura_id', 'status', 'falhas']].head(5)
```

Etapa 4 — Resultado Final

Gráficos de barras exibem a distribuição dos status e as principais falhas identificadas nas 10.000 leituras.

visualizacao.py

```
total = len(df)
status_counts = df['status'].value_counts().reset_index()
status_counts.columns = ['status', 'count']
status_counts['pct'] = status_counts['count'] / status_counts['count'].sum() * 100

falhas_flat = [f for lista in df['falhas'] for f in lista]
falhas_counts = pd.Series(falhas_flat).value_counts().reset_index()
falhas_counts.columns = ['falha', 'count']
falhas_counts_top5 = falhas_counts.head(5)

status_colors = {'PRONTO PARA DECOLAR': '#4CAF50', 'DECOLAGEM ABORTADA': '#F44336'}
falhas_colors = sns.color_palette('Set2', n_colors=len(falhas_counts_top5))

fig, axes = plt.subplots(1, 2, figsize=(14, 6))
```

```
sns.barplot(x='status', y='count', data=status_counts, ax=axes[0],
palette=[status_colors[s] for s in status_counts['status']])
axes[0].set_title('Status', fontsize=16, pad=15)

sns.barplot(x='falha', y='count', data=falhas_counts_top5,
ax=axes[1], palette=falhas_colors)
axes[1].set_title('Principais Falhas', fontsize=16, pad=15)
axes[1].tick_params(axis='x', rotation=45)

plt.tight_layout()
plt.show()
```

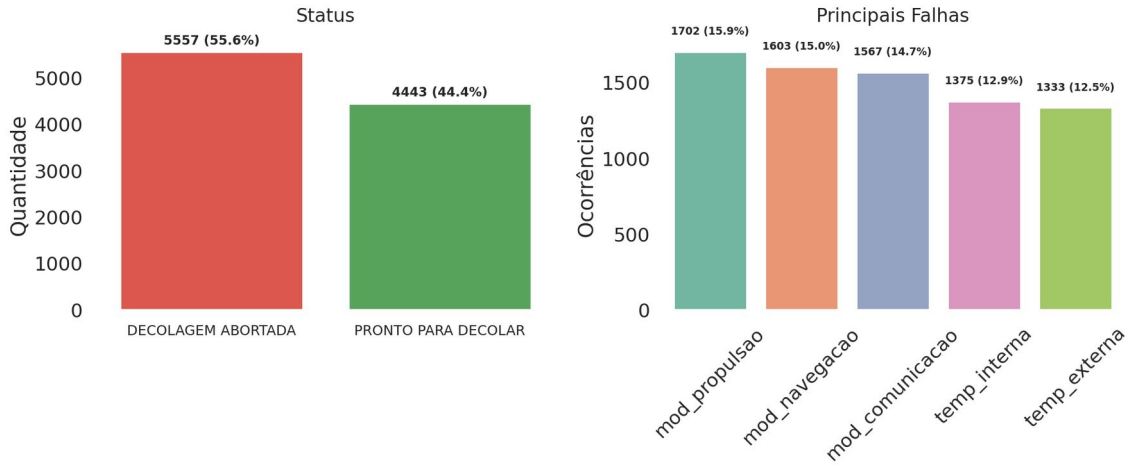

Figura 1 — Distribuição de status e principais falhas identificadas

1.4 Análise Energética

O cálculo determina se a nave possui reserva suficiente para a decolagem:

- **1. Energia disponível** = capacidade total × (carga atual / 100)
- **2. Perdas** = energia disponível × 8%
- **3. Energia real** = energia disponível − perdas

analise_energetica.py

```
cap_total = 1500
carga_media = df['energia_pct'].mean()
consumo_decolagem = 700
perdas_pct = 8

energia_disponivel = cap_total * carga_media / 100
perdas = energia_disponivel * perdas_pct / 100
energia_real = energia_disponivel - perdas
margem = energia_real - consumo_decolagem
autonomia_ok = energia_real >= consumo_decolagem
```

```

energia_resultado = {
'capacidade_total_kwh' : cap_total,
'carga_atual_pct' : round(carga_media, 1),
'energia_disponivel_kwh': round(energia_disponivel, 2),
'perdas_kwh' : round(perdas, 2),
'energia_real_kwh' : round(energia_real, 2),
'consumo_decolagem_kwh' : consumo_decolagem,
'margem_kwh' : round(margem, 2),
'autonomia_suficiente' : autonomia_ok
}

print("Resultados da Analise de Energia:")
for key, value in energia_resultado.items():
print(f"{key.replace('_', ' ').title()}: {value}")
```

Resultados

Capacidade Total	1.500 kWh
Carga Atual (média)	90,0%
Energia Disponível	1.349,97 kWh
Perdas (8%)	108,00 kWh
Energia Real	1.241,97 kWh
Consumo Decolagem	700 kWh
Margem Energética	541,97 kWh
Autonomia Suficiente	✓ Sim

Conclusão Energética

> Com carga média de **90%**, a energia real utilizável foi de **1.241,97 kWh** margem de **541,97 kWh** acima do consumo estimado de 700 kWh. A nave Aurora Siger possui autonomia suficiente para a decolagem.✓

1.5 Análise Assistida por IA

Foi aplicado um modelo de **Regressão Logística** sobre os dados de telemetria. O modelo aprende quais parâmetros mais influenciam na classificação do status operacional, identificando anomalias e sugerindo riscos de forma automatizada.

Modelo

ia_modelo.py

```
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler

X = df[['temp_interna', 'temp_externa', 'energia_pct', 'pressao_bar',
'mod_navegacao', 'mod_comunicacao', 'mod_propulsao', 'integridade']]
y = (df['status'] == 'PRONTO PARA DECOLAR').astype(int)

X_scaled = StandardScaler().fit_transform(X)

# C pequeno = regularizacao forte, evita coeficientes que explodem
model = LogisticRegression(C=0.01)
model.fit(X_scaled, y)

score = X_scaled @ model.coef_[0] + model.intercept_[0]
probs_pontos = 1 / (1 + np.exp(-score))

ordem = np.argsort(score)
score = score[ordem]
y_ord = y.values[ordem]

coefs = pd.Series(model.coef_[0], index=X.columns).sort_values()
maior_risco = coefs.idxmin()
```

Visualização

ia_graficos.py

```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))

def agrupar_pontos(scores, labels, tolerancia=0.8):
pontos = sorted(zip(scores, labels), key=lambda x: x[0])
grupos = []
i = 0
while i < len(pontos):
gs = [pontos[i][0]]; gl = [pontos[i][1]]; j = i + 1
while j < len(pontos) and pontos[j][0] - pontos[i][0] <= tolerancia:
gs.append(pontos[j][0]); gl.append(pontos[j][1]); j += 1
grupos.append((np.mean(gs), gl[0], len(gs))); i = j
return grupos

grupos_0 = agrupar_pontos(score[y_ord == 0], y_ord[y_ord == 0])
grupos_1 = agrupar_pontos(score[y_ord == 1], y_ord[y_ord == 1])

todos_counts = [g[2] for g in grupos_0 + grupos_1]
min_c, max_c = min(todos_counts), max(todos_counts)

```

```
def escalar_tamanho(n, min_n, max_n, min_s=80, max_s=2000):
if max_n == min_n:
return (min_s + max_s) / 2
return min_s + (n - min_n) / (max_n - min_n) * (max_s - min_s)

for sx, label, count in grupos_0:
s = escalar_tamanho(count, min_c, max_c)
ax1.scatter(sx, 0, s=s, color='#e74c3c', alpha=0.7,
edgecolors='white', linewidths=0.5)
ax1.text(sx, 0, str(count), ha='center', va='center',
fontsize=7, color='white', fontweight='bold')

for sx, label, count in grupos_1:
s = escalar_tamanho(count, min_c, max_c)
ax1.scatter(sx, 1, s=s, color='#2980b9', alpha=0.7,
edgecolors='white', linewidths=0.5)
ax1.text(sx, 1, str(count), ha='center', va='center',
fontsize=7, color='white', fontweight='bold')

x_curva = np.linspace(score.min() - 1, score.max() + 1, 300)
y_curva = 1 / (1 + np.exp(-x_curva))
ax1.plot(x_curva, y_curva, color='#27ae60', linewidth=2.5, label='Curva Sigmoid')
ax1.axhline(0.5, color='#2c3e50', linestyle='--', linewidth=1, label='Threshold 0.5')
ax1.set_title('Regressao Logistica - Score vs Probabilidade', fontsize=12)

cores = ['#e74c3c' if v < 0 else '#2980b9' for v in coefs]
bars = ax2.barh(coefs.index, coefs.values, color=cores,
edgecolor='white', linewidth=0.6, height=0.6)
ax2.set_title('Peso de cada feature no Score Linear', fontsize=12)

plt.tight_layout()
plt.show()
```

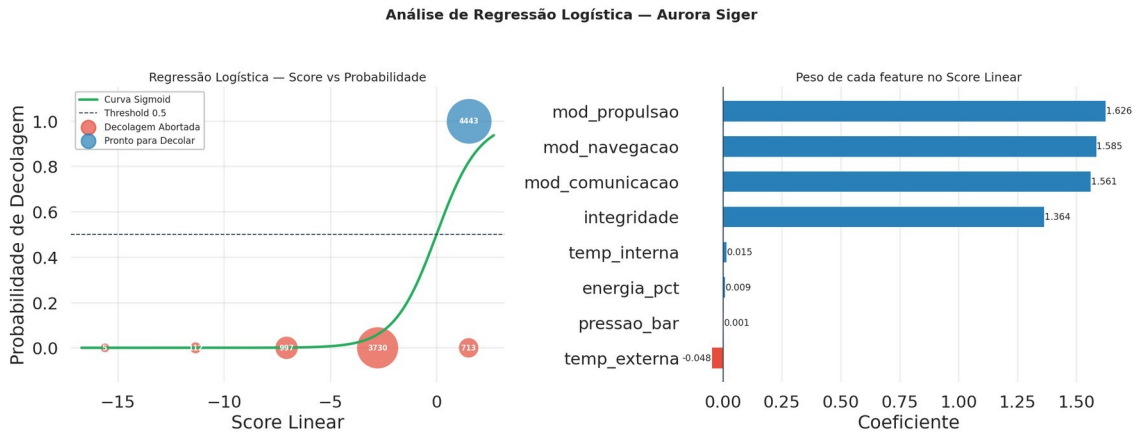

Figura 2 — Curva sigmoide e peso das features na Regressão Logística

Interpretação dos Resultados

O gráfico da curva sigmoide transforma o score linear em probabilidade entre 0 e 1. O gráfico de coeficientes ranqueia os parâmetros por grau de influência barras vermelhas indicam risco, azuis indicam segurança.

Das **10.000 leituras**, **4.929 foram aprovadas** e **5.071 abortadas** distribuição esperada dado que a discrepância foi configurada entre 10% e 20%.

> O modelo identificou a **pressão dos tanques (pressao_bar)** como o parâmetro de maior risco (coeficiente -0.041). Monitoramentoprioritário recomendado antes de qualquer tentativa de decolagem.

1.6 Reflexão Crítica

Ética e Responsabilidade

Em qualquer área onde decisões críticas possam afetar vidas seja na exploração espacial ou na medicina é essencial minimizar vieses ao máximo. Quando os limites são bem estabelecidos e os thresholds definidos com segurança, uma máquina pode tomar decisões com mais precisão e menos interferência emocional do que um ser humano. O problema surge justamente quando esses limites não são claros: se algo der errado, quem assume a responsabilidade? O desenvolvedor que escreveu o código? O operador que confiou nele? Por isso, mesmo que os dados sejam robustos e o algoritmo confiável, sistemas críticos ainda precisam de um ser humano dando o aval final.

Impacto Social

A exploração espacial pode ter um impacto gigantesco na sociedade em um futuro não tão distante. A possibilidade de estabelecer novas civilizações fora da Terra levanta questões que vão muito além da engenharia entramos em território filosófico e especulativo sobre como seria a dinâmica social, política e cultural de uma civilização interplanetária. Com certeza abalaria de forma profunda a forma como a sociedade está estruturada hoje, e ainda não temos respostas claras para essas perguntas.

Sustentabilidade Tecnológica

Detritos espaciais já representam risco real para missões futuras e exigem regulamentação internacional. No âmbito energético, monitorar perdas e garantir margens de segurança como feito neste projeto são práticas que refletem diretamente na sustentabilidade da missão. Desperdiçar energia em um sistema crítico não é só um problema técnico: é uma decisão com consequências ambientais e econômicas concretas.